Análisis sintáctico

Pedro O. Pérez M., PhD.

Implementación de métodos computacionales
Tecnológico de Monterrey

pperezm@tec.mx

04-2021

Contenido I

Introducción

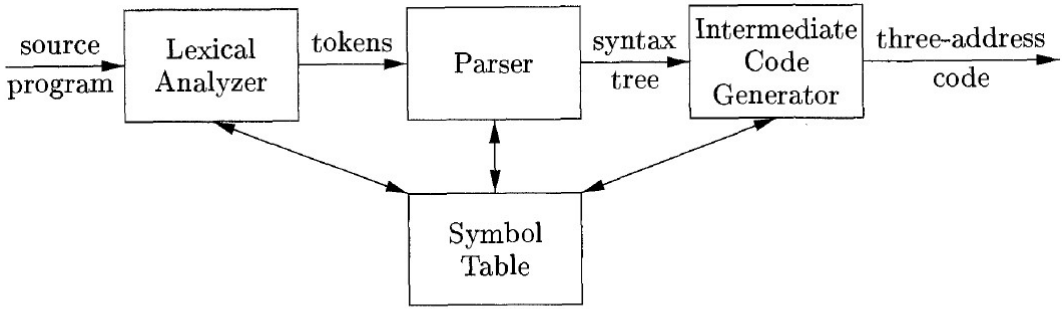

Figure 2.3: A model of a compiler front end

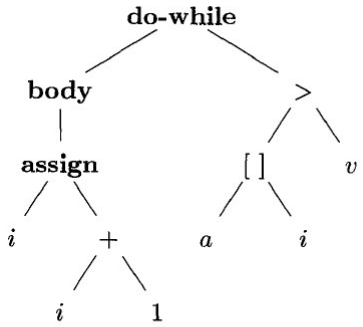

(a)

```
1: i = i + 1
2: t1 = a [ i ]
3: if t1 < v goto 1
```

(b)

Figure 2.4: Intermediate code for "`do i=i+1; while(a[i]<v);`"

Componentes de una gramática

Una gramática libre de contexto tiene 4 componentes:

- Un conjunto de símbolos `terminales` llamados "`tokens`".
- Un conjunto de símbolos `no terminales`, algunas veces llamados "`variables sintática`".
- Un conjunto de `producciones`, donde cada producción consiste de un `no terminales`, llamado `encabezado` o `lado izquierdo` de la producción, una flecha y una secuencia de `terminales` y `no-terminales`, llamados `cuerpo` o `lado derecho` de la producción.
- La designación de uno de los `no-terminales` como símbolo de `inicio`.

$$list \rightarrow list + digit \quad (1)$$
$$list \rightarrow list - digit \quad (2)$$
$$list \rightarrow digit \quad (3)$$
$$digit \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9 \quad (4)$$

ϵ - cadena vacía

Árbol de análisis

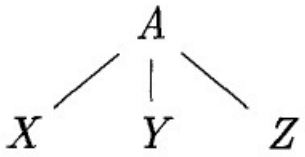

- La raíz está etiquetada con el símbolo de inicio.
- Cada hoja está etiquetada con un `terminal` o ϵ.
- Cada nodo interior está etiquetado con un `no terminal`.
- Si `A` es la etiqueta de un nodo interno y $X_1, X_2, ..., X_n$, entonces existe una producción $A \rightarrow X_1 X_2 ... X_n$.

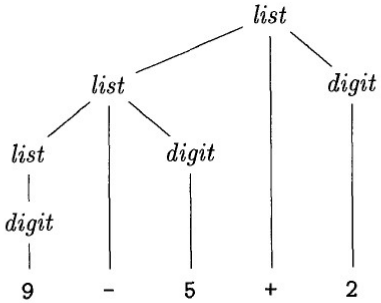

Figure 2.5: Parse tree for 9−5+2 according to the grammar in Example 2.1

$$string \rightarrow string + string \tag{5}$$

$$string \rightarrow string - string \tag{6}$$

$$string \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9 \tag{7}$$

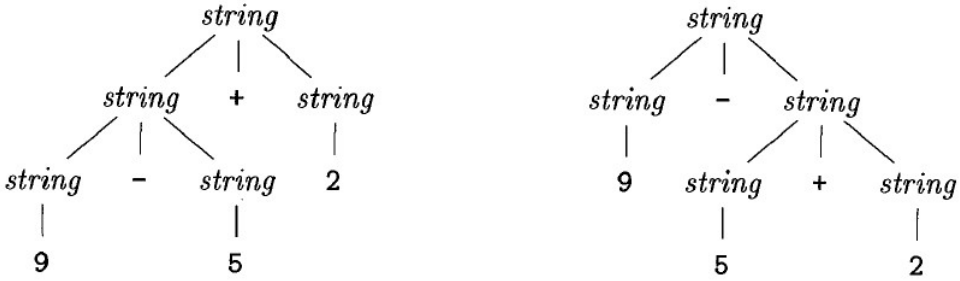

Figure 2.6: Two parse trees for 9-5+2

Asociatividad de operadores

$$list \rightarrow list + digit \tag{8}$$
$$list \rightarrow list - digit \tag{9}$$
$$list \rightarrow digit \tag{10}$$
$$list \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9 \tag{11}$$
$$right \rightarrow letter = right \tag{12}$$
$$right \rightarrow letter \tag{13}$$
$$letter \rightarrow a \mid b \mid ... \mid z \tag{14}$$

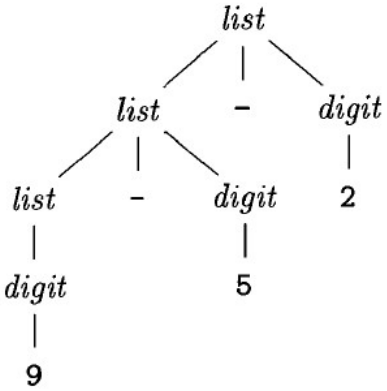

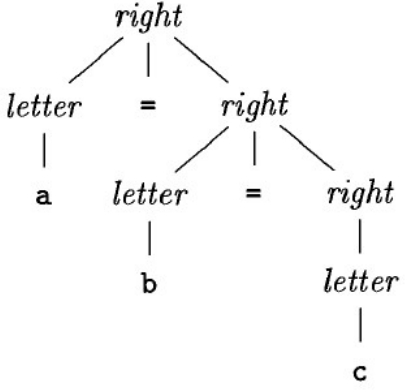

Figure 2.7: Parse trees for left- and right-associative grammars

Precedencia de operadores

$$expr \rightarrow expr + term \mid expr - term \mid term \tag{15}$$
$$term \rightarrow term * factor \mid term/factor \mid factor \tag{16}$$
$$factor \rightarrow digit \mid (expr) \tag{17}$$

En general los analizadores se pueden catalogar como: `top-down` (LL) o `bottom-up` (LR). Por ahora nos enfocaremos en **un analizador de descenso recursivo**.

- Es el más usado cuando realizamos un traductor simple dirigido por sintaxis.
- Aunque no es el más eficiente, ya que para cualquier gramática libre de contexto este analizador requiere un tiempo $O(n^3)$ para hacer su trabajo.

Análisis Top-Down

$$
\begin{array}{lcl}
\textit{stmt} & \rightarrow & \textbf{expr ;} \\
 & | & \textbf{if (expr)} \ \textit{stmt} \\
 & | & \textbf{for (} \ \textit{optexpr} \ \textbf{;} \ \textit{optexpr} \ \textbf{;} \ \textit{optexpr} \ \textbf{)} \ \textit{stmt} \\
 & | & \textbf{other} \\
 & & \\
\textit{optexpr} & \rightarrow & \epsilon \\
 & | & \textbf{expr}
\end{array}
$$

Figure 2.16: A grammar for some statements in C and Java

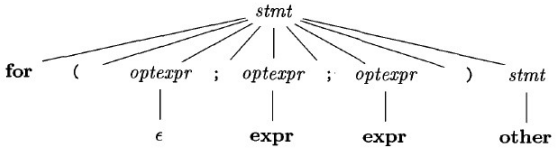

Figure 2.17: A parse tree according to the grammar in Fig. 2.16

Construcción top-down de un árbol de análisis:

- Para un node N, etiqueda con un no `terminal` A, selecciona una de las producción existentes para A y genera los hijos de N.
- Encuentra el siguiente nodo cuyo subárbol no se haya construido.

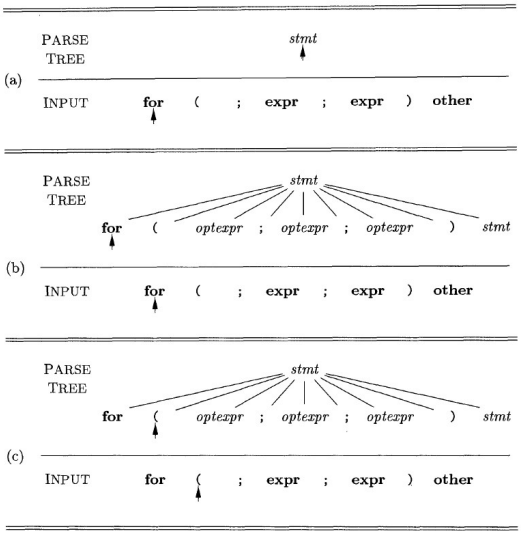

Figure 2.18: Top-down parsing while scanning the input from left to right

En general, la selección de una producción para un no `terminal` puede involucrar un proceso de prueba-y-error.

Análisis de descenso recursivo

Un analizador de descenso recursivo (ADR) emplea un método de análisis top-down en el cual un conjunto de procedimientos recursivos son usados para procesar la entrada. Existe un procedimiento asociado a cada `no terminal` de la gramática. En nuestro caso, revisaremos una forma simple de análisis de descenso recursivo llamado análisis predictivo, el cual emplea la lectura previa de un símbolo no ambigüo (`lookahead`) para determinar el flujo del proceso.

```
void stmt() {
        switch ( lookahead ) {
        case expr:
                match(expr); match(';'); break;
        case if:
                match(if); match('('); match(expr); match(')'); stmt();
                break;
        case for:
                match(for); match('(');
                optexpr(); match(';'); optexpr(); match(';'); optexpr();
                match(')'); stmt(); break;
        case other;
                match(other); break;
        default:
                report("syntax error");
        }
}

void optexpr() {
        if ( lookahead == expr ) match(expr);
}

void match(terminal t) {
        if ( lookahead == t ) lookahead = nextTerminal;
        else report("syntax error");
}
```

Figure 2.19: Pseudocode for a predictive parser

El ADR se basa en la información obtenida de los primeros símbolos que genera una producción (FIRST).

$$
\begin{array}{lcl}
\textit{stmt} & \rightarrow & \textbf{expr ;} \\
 & | & \textbf{if (expr)} \ \textit{stmt} \\
 & | & \textbf{for (} \ \textit{optexpr} \ \textbf{;} \ \textit{optexpr} \ \textbf{;} \ \textit{optexpr} \ \textbf{)} \ \textit{stmt} \\
 & | & \textbf{other} \\
 & & \\
\textit{optexpr} & \rightarrow & \epsilon \\
 & | & \textbf{expr}
\end{array}
$$

Figure 2.16: A grammar for some statements in C and Java

- Un ADR utiliza una producción ϵ como acción por omisión cuando no existe una producción que pueda ser usada.
- Es importante mencionar que si queremos emplear este tipo de analizador, la gramática a reconocer debe tener conjuntos disjuntos `FIRST` para cualquier `no terminal`.

Como se mencionó anteriormente, un ADR es un programa que consiste de un procedimiento para cada `no terminal`. El procedimiento para el `no terminal` A hace dos cosas:

- Decide cual producción A usar examinando el símbolo `lookahead`. La producción con el cuerpo α es usado si el símbolo `lookahead` está en el conjunto `FIRST`(α).
- A continuación, el procedimiento reproduce el cuerpo de la producción elegida.

Recursión por la izquierda

La recursión por la izquierda es un problema grave para este tipo de analizadores, ya que los hace caer en un ciclo sin fin.

$$expr \rightarrow expr + term \tag{18}$$

Para resolver este problema ha que reescribir la producción. Si tenemos una producción del estilo:

$$A \rightarrow A\alpha|\beta \tag{19}$$

$$\begin{array}{lcl} E & \rightarrow & E + T \mid T \\ T & \rightarrow & T * F \mid F \\ F & \rightarrow & (E) \mid \mathbf{id} \end{array}$$

Reescribimos la producción A, usando una nueva `no terminal` R:

$$A \rightarrow \beta R \tag{20}$$

$$R \rightarrow \alpha R|\epsilon \tag{21}$$

Conjunto FIRST

- FIRST(α), donde α es cualquier cadena de símbolos de la gramática, es el conjunto de terminales que empieza una secuencia de cadenas que derivan de α.

$$
\begin{array}{lcl}
E & \rightarrow & T\ E' \\
E' & \rightarrow & +\ T\ E' \mid \epsilon \\
T & \rightarrow & F\ T' \\
T' & \rightarrow & *\ F\ T' \mid \epsilon \\
F & \rightarrow & (\ E\ ) \mid \mathbf{id}
\end{array}
$$

1. If X is a terminal, then $\text{FIRST}(X) = \{X\}$.
2. If X is a nonterminal and $X \rightarrow Y_1 Y_2 \cdots Y_k$ is a production for some $k \geq 1$, then place a in $\text{FIRST}(X)$ if for some i, a is in $\text{FIRST}(Y_i)$, and ϵ is in all of $\text{FIRST}(Y_1), \ldots, \text{FIRST}(Y_{i-1})$; that is, $Y_1 \cdots Y_{i-1} \stackrel{*}{\Rightarrow} \epsilon$. If ϵ is in $\text{FIRST}(Y_j)$ for all $j = 1, 2, \ldots, k$, then add ϵ to $\text{FIRST}(X)$. For example, everything in $\text{FIRST}(Y_1)$ is surely in $\text{FIRST}(X)$. If Y_1 does not derive ϵ, then we add nothing more to $\text{FIRST}(X)$, but if $Y_1 \stackrel{*}{\Rightarrow} \epsilon$, then we add $\text{FIRST}(Y_2)$, and so on.
3. If $X \rightarrow \epsilon$ is a production, then add ϵ to $\text{FIRST}(X)$.

Ver código fuente

Traducción dirigida por sintaxis es hecha al agregar reglas o fragmentos de código a las producciones de una gramática.
En este rubro, existen dos conceptos importantes:

- **Atributos.** Un atributo es cualquier cantidad asociada con una construcción de programación.
- **Esquemas de traducción dirigida por sintaxis.** Un esquema de traducción es una notación que agrega fragmentos de programa a las producciones una gramática.

Notación postfija para una expresión E se define:

- Si E es una variable o constante, entonces la notación postfija para E es la misma expresión E.
- Si E es una expresión de la forma E_1 **op** E_2, donde **op** es un operador binaria, entonces la notación postfija para E es E_1' E_2' **op**, donde E_1' y E_2' son las notaciones postfija para E_1 y E_2, respectivamente.
- Si E es una expresión encerar en paréntesis de la forma (E_1), entonces la notación postfija es la misma que la notación postfija de E_1.

Asociamos atributos a los `terminales` y `no terminales`. Entonces, agregamos reglas de traducción a las producciones de la gramática. Estas reglas describen como los atributos son calculados en los nodos del árbol de análisis donde la producción.

	Production	Semantic Rules
1)	$T \to F\ T'$	$T'.inh = F.val$ $T.val = T'.syn$
2)	$T' \to *\ F\ T'_1$	$T'_1.inh = T'.inh \times F.val$ $T'.syn = T'_1.syn$
3)	$T' \to \epsilon$	$T'.syn = T'.inh$
4)	$F \to \mathbf{digit}$	$F.val = \mathbf{digit}.lexval$

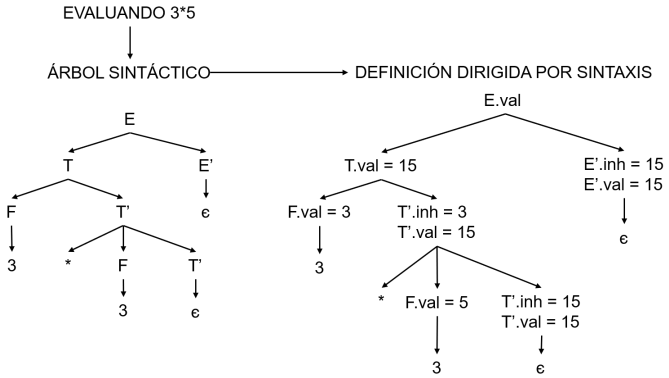

Ver código fuente